




درس مبانی بینایی ماشین

Low-Light Image Enhancement Project

آریا نادری ۴۰۱۱۲۳۵۸۰۴۳

چکیده

بهبود کیفیت تصاویر کم نور امروزه به چالشی جدی در زمینه کامپیوتر تبدیل شده است. با رشد روز افزون هوش مصنوعی و استفاده از آن در زمینه های مختلف مانند بررسی تصاویر MRI، تصاویر ماهواره ای و... بهبود تصاویر از اهمیت ویژه ای برخوردار است. در این پروژه به بررسی تصاویر کم نور و بهبود کیفیت آن ها می پردازیم. عموماً در اینگونه تصاویر به علت نور کم و کنتراست پایین جزئیاتی که بعضاً اهمیت زیادی دارند از بین می روند و یا برای مدلی که قصد یادگیری آن را دارد، کیفیت لازم را ندارند.

در این پروژه ابتدا تفاوت بین تصاویر با نور کم و تصاویر با نور نرمال رو با استفاده از ویژگی هایی مثل Mean Logistic Intensity، Contrast، Entropy، Histogram Skewness بررسی می کنیم سپس از مدل Logistic Regression استفاده می کنیم تا تصاویر کم نور و تصاویر نرمال را طبقه بندی کنیم و در نهایت با روش های کلاسیکی مثل Clahe، Histogram Equalization و Gamma correction استفاده می کنیم و تصاویر را بهبود می دیم. لازم به ذکر است در این پروژه از دیتاست LOL-v2 استفاده شده است. در بخش بعدی پروژه یک Autoencoder ساده نیز آموزش داده می شود که تصاویر کم نور را بهبود دهد و در نهایت نتایج را با پارامتر های SSIM و PSNR مقایسه می کنیم. بهترین نتیجه را مدل Autoencoder با مقادیر 0.81 و 20.35 به ترتیب برای SSIM و PSNR گرفت.

فهرست مطالب

مقدمه	۳
روش انجام پروژه	۴
محیط آزمایش و پیاده‌سازی	۷
نتایج	۷
بحث و تحلیل	۱۲
نتیجه گیری	۱۳

مقدمه

یکی از مهم ترین عناصر هر تصویر نور آن است. هنگام آموزش یک مدل هوش مصنوعی برای پردازش تصاویر باید تمامی اجزای عکس از جمله نور، در ایده آل ترین حالت خود باشد اما در واقعیت چنین نیست و در اکثر تصاویر MRI و یا تصاویر ماهواره ای و ... به علت محدودیت های دستگاه عکس گیرنده ممکن نیست. در این اینگونه تصاویر به علت واضح نبودن جزئیات تشخیص اجزای عکس بسیار دشوار است و بعضا این مسئله تاثیر به سزایی روی دقت مدل هوش مصنوعی می گذارد. به همین دلیل بهبود اینگونه تصاویر از اهمیت ویژه ای برخوردار است.

در این پروژه هدف بررسی و استفاده از روشی مبتنی بر یادگیری عمیق است که نسبت به روش های کلاسیک نتایج بهتری دارد و در پارامتر های معرفی شده برتری قابل توجه این روش نسبت به روش های کلاسیک مشهود است البته شایان ذکر است در این پروژه فقط به بررسی پارامتر ها اکتفا نکردیم و مقایسه بصری هم صورت گرفته است. علاوه بر آن با تحلیل تفاوت های آماری، مشخص شد که می توان با دقت کامل تصاویر کم نور و تصاویر نرمال رو از یکدیگر تشخیص داد.

روش انجام پروژه

پروژه دارای ۳ فاز مختلف می‌باشد. قبل از شروع فاز ها به پیش پردازش (Preprocess) تصاویر می‌پردازیم. بدون پیش‌پردازش درست تصاویر عملاً انجام پروژه امکان پذیر نخواهد بود و نتایج مورد نظر به دست نخواهد آمد. در فاز پیش‌پردازش ابتدا تصاویر رو به مقدار دلخواه برداشته و آنها را به فرمت RGB تبدیل می‌کنیم و سپس ابعاد تصاویر رو $256 * 256$ تغییر می‌دهیم و بعد آن هارا نرمال سازی می‌کنیم.

بعد از انجام نرمال سازی نوبت به فاز اول پروژه می‌رسد. در این فاز هدف بررسی ویژگی های آماری تصاویر نرمال و کم نور می‌باشد. در این بخش در ابتدا دیتاست خود را ایجاد می‌کنیم. این دیتاست شامل ویژگی های Mean Intensity, Contrast, Entropy, Histogram Skewness است که اطلاعاتی راجع به شدت روشنایی، پراکندگی شدت پیکسل ها، و نمودار هیستوگرام تصویر را ارائه می‌دهد. مطابق هر تسک طبقه بندی ای بعد از ایجاد دیتاست آن را به مجموعه آموزش و آزمون تقسیم کرده و سپس آن هارا استاندارد می‌کنیم. بعد از آماده شدن مجموعه های آزمون و آموزش یک مدل Logistic Regression را با هایپر پارامتر های دیفالت کتابخانه sickit-learn آموزش می‌دهیم تا بتواند عملیات طبقه بندی را انجام دهد. در بخش نتایج بیشتر راجع به عملکرد این مدل صحبت می‌کنیم اما شایان ذکر است که مدل توانست با دقت صد در صد تصاویر را طبقه بندی کند.

در فاز ۲ هدف بررسی عملکرد روش های کلاسیک بهبود تصاویر مانند Gamma Correction, Clahe و Histogram Equalize و مقایسه آن ها با یک Autoencoder مبتنی بر یادگیری عمیق است. در ابتدا توضیحاتی راجع به روش های کلاسیک می‌دهیم و در ادامه به توضیح معماری Autoencoder می‌پردازیم و در بخش نتایج نیز به صورت مفصل درباره عملکرد آن ها بحث می‌کنیم.

روش Clahe را می‌توان نسخه ی بهبود یافته HE تلقی کرد. در HE کل تصویر یک histogram دارد و روی کل تصویر یک بتدیل اعمال می‌کنیم اما در روش Clahe کنتراست را به صورت محلی افزایش میابد. به این صورت که تصویر به بلوک های کوچک تقسیم می‌شود، برای هر بلوک یک histogram ساخته می‌شود سپس کنتراست هر ناحیه به طور جداگانه افزایش میابد. با انجام این کار جزئیات محلی بهتر دیده می‌شوند.

روش Gamma Correction یک روش برای تنظیم روشنایی و کنتراست تصویر به صورت غیرخطی است. این روش با یک تابع توان شدت پیکسل هارا اصلاح می‌کند تا تصاویر طبیعی تر دیده شود. فرمول این روش به این صورت است:

$$I_{out} = I_{in}^{\gamma}$$

I_{out} پیکسل خروجی و I_{in} پیکسل ورودی است. اگر γ مقداری کوچک تر از یک باشد تصویر روشن تر و اگر مقداری بزرگ تر از یک داشته باشد تصویر تاریک تر می شود.

روش **SSR** که برگرفته از روش Retinex است، تخمین نور محیط را با استفاده از فیلتر Gaussian انجام می دهد. نور محیط معمولاً تغییرات آهسته دارد بنابراین با blur کردن تصویر می توان آن را تخمین زد. فرمول این روش به این صورت است:

$$R(x, y) = \log(I(x, y)) - \log(F(x, y) * I(x, y))$$

که در آن I تصویر ورودی، F فیلتر Gaussian، $*$ عمل convolution و R تصویر خروجی است.

در ابتدای بخش اول فاز ۲ تصویر خروجی این روش هارا باهم مقایسه می کنیم. از لحاظ بصری بهترین عملکرد را روش گاما دارد.

در بخش بعدی فاز ۲ مدل طراحی شده یک Autoencoder کانولوشنی بهبود یافته است که ساختاری شبیه به معماری U-Net دارد. هدف این مدل استخراج ویژگی های مهم تصویر در بخش Encoder و بازسازی تصویر در بخش Decoder است.

در بخش Encoder چندین لایه کانولوشن به همراه تابع فعال سازی LeakyReLU و نرمال سازی دسته ای (Batch Normalization) استفاده شده است. در هر مرحله با استفاده از MaxPooling ابعاد مکانی تصویر کاهش یافته و تعداد کانال ها افزایش می یابد تا ویژگی های سطح بالاتر استخراج شوند.

در مرکز شبکه یک بخش Bottleneck قرار دارد که شامل چند لایه کانولوشن عمیق است. این بخش نقش فشرده سازی و یادگیری نمایش انتزاعی از تصویر را بر عهده دارد و مهم ترین ویژگی های تصویر در آن استخراج می شوند.

در بخش Decoder برای بازگرداندن ابعاد تصویر از لایه های ConvTranspose2d (Upsampling) استفاده شده است. پس از هر مرحله Upsampling، ویژگی های متناظر از بخش Encoder با استفاده از اتصالات میان بر (Skip) است.

Connections) به Decoder متصل می‌شوند. این اتصال‌ها باعث حفظ جزئیات مکانی تصویر و بهبود کیفیت بازسازی می‌شوند.

در نهایت یک لایه کانولوشن با سه کانال خروجی و تابع فعال‌سازی Sigmoid قرار دارد که تصویر بازسازی‌شده را در بازه $[0,1]$ تولید می‌کند.

به طور کلی این معماری با ترکیب Encoder-Decoder عمیق، Bottleneck و Skip Connections قادر است ویژگی‌های پیچیده تصویر را یاد گرفته و تصویر ورودی را با دقت مناسبی بازسازی کند.

برای آموزش این مدل مطابق محدودیت‌های پروژه از ۳۰ epoch و از تابع هزینه MSE Loss استفاده شده است که اختلاف پیکسل به پیکسل عکس خروجی مدل با عکس هدف را بررسی می‌کند. همچنین یک مکانیزم early stopping برای صرفه جویی در زمان آموزش و همچنین گرفتن بهترین نتیجه نیز تعبیه شده است. در نهایت تصاویر خروجی با معیارهای PSNR و SSIM سنجیده می‌شوند. این معیارها میزان شباهت تصاویر بازسازی شده و تصاویر اصلی (Ground truth) را نشان می‌دهند.

PSNR مخفف Peak Signal-to-Noise Ratio است و برای اندازه‌گیری میزان خطا بین دو تصویر استفاده می‌شود.

در واقع PSNR از روی MSE (Mean Squared Error) محاسبه می‌شود.

فرمول آن به صورت زیر است:

$$PSNR = 10 \log_{10} \left(\frac{MAX_I^2}{MSE} \right)$$

MAX_I به معنای بیشترین مقدار شدت پیکسل است که در دیتاست ما برابر با مقدار ۲۵۵ است. به طور کلی هرچه مقدار PSNR بزرگ‌تر باشد کیفیت تصویر بهتر است. معمولاً از بازه بندی زیر استفاده می‌شود:

> 20 dB → کیفیت ضعیف

> 20 – 30 dB → کیفیت متوسط

> 30 – 40 dB → کیفیت خوب

> 40 dB → کیفیت بسیار خوب

اما مشکل این معیار این است که فقط اختلاف عددی پیکسل هارا بررسی می کند و همیشه با ادراک بصری انسان همخوانی ندارد.

معیار دیگر SSIM است مخفف Structural Similarity Index است.

این معیار تلاش می کند شباهت دو تصویر را بر اساس ساختار تصویر اندازه گیری کند، مشابه چیزی که چشم انسان درک می کند. SSIM ویژگی های روشنایی، کنتراست و ساختار را مقایسه می کند. اگر SSIM مقداری نزدیک به یک داشته باشد به معنای کاملاً مشابه و اگر مقدار صفر داشته باشد شباهت بسیار کم و اگر مقداری منفی داشته باشد به معنای تفاوت زیاد است.

در فاز ۳ این پروژه تصاویر دیتاست آزمون را با معیار های PSNR و SSIM و روش های نام برده شده می سنجم تا مقایسه کنیم در نهایت کدام یک برنده این جدال خواهند شد. همانطور که انتظار میرفت مدل Autoencoder عملکرد بسیار بهتری نسبت به سایر روش ها داشت.

محیط آزمایش و پیاده سازی

این پروژه روی کارت گرافیک nvidia RTX 3050 و با مصرف ۳.۷ گیگابایت حافظه با ۱۶ گیگابایت رم اجرا شده است.

در این پروژه از کتابخانه های متنوعی از جمله torch, numpy, sklearn و matplotlib استفاده شده است. دیتاست مورد استفاده برای آموزش شامل ۸۰ تصویر و برای آموزش شامل ۲۰ تصویر است. همانطور که گفته شده 30 epoch برای آموزش با نرخ یادگیری 0.0002 استفاده شده است همچنین از یک scheduler استفاده شده است تا در صورت نیاز مقدار نرخ یادگیری به صورت پویا تغییر کند.

نتایج

تصویر زیر نتیجه طبقه بندی مدل Logistic Regression را نشان می دهد.


Logistic Regression: نتایج ارزیابی مدل

Accuracy (دقت کل): 1.0000

Precision (دقت مثبت): 1.0000

Recall (فراخوانی): 1.0000

F1-Score (معیار ترکیبی): 1.0000




همانطور که در تصویر مشخص است مقدار Precision و Recall برای این مدل در طبقه بندی تصاویر برابر با عدد ۱ و به معنای دقت کامل است.

Input Low-Light




Normal Reference




Histogram Eq (HE)



CLAHE




Gamma (0.4)



Retinex (SSR)





تصویر بالا نتیجه اعمال روش های کلاسیک رو یکی از عکس های دیتاست می باشد.




رسم نمودار Loss در هر epoch.

تصاویر زیرین نیز خروجی Autoencoder را نشان می‌دهد.



Input (Low-Light)




Raw Model Output



Ground Truth (Normal-Light)



Input (Low-Light)




Raw Model Output



Ground Truth (Normal-Light)



Input (Low-Light)



Raw Model Output



Ground Truth (Normal-Light)




Input (Low-Light)




Raw Model Output



Ground Truth (Normal-Light)





در نهایت مقایسه نتایج روش های مختلف رو هم به صورت یک نمودار داریم.

بحث و تحلیل

۱. چرا گاهی مقادیر بالاتر PSNR می توانند با کیفیت بصری بدتر همراه باشند؟

معیار PSNR تنها بر اساس اختلاف عددی بین پیکسل های تصویر اصلی و تصویر بازسازی شده محاسبه می شود و از معیار MSE استفاده می کند. به همین دلیل این معیار فقط خطای پیکسلی را اندازه گیری می کند و ساختار یا ادراک بصری تصویر را در نظر نمی گیرد. در برخی موارد ممکن است الگوریتمی تصویر را بیش از حد هموار (over-smoothing) کند و جزئیات مهم تصویر از بین بروند. در چنین حالتی مقدار خطای پیکسلی ممکن است کم باشد و PSNR بالا گزارش شود، اما از نظر بصری تصویر طبیعی یا واضح به نظر نرسد. بنابراین PSNR همیشه بازتاب دقیقی از کیفیت ادراکی تصویر برای انسان نیست.

۲. در چه شرایطی روش های کلاسیک می توانند بهتر از Autoencoder عمل کنند؟

روش های کلاسیک مانند CLAHE، Gamma Correction یا Retinex معمولاً بر اساس قوانین مشخص و قابل تفسیر عمل می کنند و در شرایطی که داده آموزشی محدود باشد می توانند عملکرد پایدارتری داشته باشند. همچنین در تصاویر ساده یا زمانی که هدف فقط افزایش روشنایی یا کنتراست باشد، این روش ها ممکن است نتایج سریع و قابل قبولی تولید کنند. در مقابل، Autoencoder برای یادگیری الگوهای مناسب نیاز به داده آموزشی کافی دارد و در صورت کم بودن داده یا تنوع پایین آن به شکلی که داده آموزشی نتواند مجموعه ای نماینده از حالت های متنوع ایجاد کند ممکن است عملکرد ضعیف تری داشته باشد.

۳. رابطه مبادله‌ای بین افزایش روشنایی و تقویت نویز چیست؟

در بسیاری از روش‌های افزایش روشنایی، مقدار شدت پیکسل‌ها افزایش می‌یابد. با این حال نویز موجود در تصویر نیز بخشی از همان سیگنال است و هنگام افزایش روشنایی تقویت می‌شود. در نتیجه اگر روشنایی بیش از حد افزایش یابد، نویز نیز بیشتر نمایان می‌شود و کیفیت تصویر کاهش پیدا می‌کند. بنابراین یک تعادل میان افزایش روشنایی و حفظ کیفیت تصویر لازم است تا جزئیات مفید تقویت شوند بدون اینکه نویز بیش از حد برجسته شود.

۴. آیا افزایش روشنایی همیشه به معنای کیفیت بهتر تصویر است؟

افزایش روشنایی به تنهایی لزوماً به معنای بهبود کیفیت تصویر نیست. اگر روشنایی بیش از حد افزایش یابد، ممکن است بخش‌هایی از تصویر اشباع شوند (*overexposure*) و جزئیات از بین بروند. علاوه بر این، افزایش بیش از حد روشنایی می‌تواند کنتراست تصویر را کاهش داده و نویز را بیشتر نمایان کند. بنابراین کیفیت تصویر به عوامل مختلفی مانند کنتراست، حفظ جزئیات، ساختار تصویر و سطح نویز وابسته است و نه صرفاً میزان روشنایی.

نتیجه گیری

در این پروژه مسئله تصاویر کم نور بررسی شد. در ابتدا با آموزش یک مدل Logistic Regression آموزش داده شد تا تصاویر کم نور و نرمال را طبقه بندی کند. در بخش نتایج دیدیم که این مدل با دقت کامل توانست تصاویر را طبقه بندی کند. در بخش بعدی با اعمال روش‌های کلاسیک و یک Autoencoder شبیه به مدل U-net با تابع هزینه MSE Loss و epoch 30 آموزش، توانستیم تصاویر را بهبود قابل توجهی دهیم. و در بخش نتایج دیدیم که بهترین روش استفاده از Autoencoder بود با مقادیر PSNR برای 20.38 و SSIM برای 0.80.

به طور کلی این پروژه نشان دهنده این است که استفاده از روش‌های مبتنی بر یادگیری عمیق می‌تواند نسبت به روش‌های کلاسیک عملکرد بسیار بهتری داشته باشد هرچند که در عین حال هزینه آن نیز بسیار بیشتر از روش‌های کلاسیک است.

